

Jurkat cap40：数据量与扰动效应重复性的权衡

固定训练样本，100次分层拆半；control与验证/测试保持原样。

主要结果	原始	cap40
训练扰动细胞	128,266	47,836 (-62.7%)
拆半 Pearson Δ 条件均值	0.3739	0.2618
有效条件 / 全部条件	1331 / 1335	1331 / 1335




图1 | 左：条件均值分布；中：受影响条件原/采样对照；右：重复性差值与原细胞数。

采样和计算

只采样训练扰动细胞，每条件保留 min(40,Np)，种子42；按 batch比例配额，无放回抽样。保留全部1335条件和6506个变量，统计使用原5000个表达基因。

每个条件拆成互不重叠的两组，各batch及整体两侧行数相差不超过1。两组先计算表达均值，再减去同一原始上下文control池均值，最后在基因轴算Pearson Δ。重复100次后，先条件内平均，再对条件等权平均。

$r[p,k] = \text{corr}(\mu[A] - c[p], \mu[B] - c[p])$
 $r[p] = \text{mean}(k=1..100) r[p,k]$
总体结果 = 对有效条件 $r[p]$ 等权平均。

317个条件原细胞数≤40，结果完全不变；1018个条件下采样。四个单细胞条件无法拆半，记缺失而非0。100次是同一固定样本的重复拆半，并非100份下采样数据。

结果与解释

原细胞数	条件	原始	cap40
1-40	317	0.2687	0.2687
41-80	411	0.3704	0.3022
81-160	452	0.4028	0.2384
>160	155	0.5117	0.2089

原/采样配对差均值 -0.1122；条件bootstrap 95%描述区间 [-0.1188,-0.1058]。这是重复性统计，不是理论预测上限，也不是生物重复置信区间。

保留40行 vs 完整原均值为0.7991，但两者重叠；保留行 vs 删除行仅0.3736。这两种样本量也不同，不能混为同一估计量。

总表达相关性仍达0.9630，不能代替扰动变化稳定性。866个条件丢失至少一个原batch的细胞覆盖。cap40减少训练数据，也同时改变batch覆盖及row_mean条件权重。

复现、完整产物清单与验收

没有启动训练，没有替换canonical数据，没有切换B0默认数据。

保留数据与验收

分区	原始	采样后
训练扰动	128,266	47,836
control	12,013	12,013
验证扰动	41,235	41,235
测试扰动	54,658	54,658
其他排除行	2,805	2,805
总行数	238,977	158,547

衍生H5AD保留所有基因与保留行的原始表达，逐值及dtype精确一致，obs/var分类字典严格一致。原H5AD和四份冻结manifest哈希前后不变。主会话独立核对行集合、顺序、分区、每条件数量与267,000条统计。exit0、COMPLETE、zero-PKL均通过。

成功运行耗时90.85秒；仅CPU，数值库4线程。训练行数减少62.7%，但验证与终态测试未减少，因此不能直接推断总训练时长。尚无cap40训练性能或模型效果证据。

首次基因身份核对、第二次类别字典检查的失败目录均保留。未放宽校验、未覆盖旧run。最后本地与服务器定向测试均8项通过。

所有产物及图数据

- 服务器保留：
- cap40.h5ad：158547×6506，4.143GB。
 - selection.json：固定行ID、条件与哈希，2.72MB。
 - repeat_scores.csv：267000条逐次记录，16.84MB。
- 小型产物：
- conditions.json：图1的全部作图数据。
 - summary.json：汇总与分层统计。
 - comparison.png / comparison.pdf：同一图。
 - artifact-index.json：全部文件大小与SHA256。
 - receipt / COMPLETE / launch / exit / publication / tests / acceptance：版本及终态证据。

服务器根（所有大文件留在服务器）：
/data/yilangliu/GraD-Pert/development/
jurkat-cap40-5a8a7bb-20260930T094437Z

分析源码：5a8a7bb6712bc4facdfcb13d8dd629bd0f250880

配置SHA256：
1e692732fca3fad57a713ada9475be71a9bce785563d7a5d1b53ec01850cb80f

衍生H5AD SHA256：
9cb901ead750d82f96cf85016e409b863643e340c043ff8c3aef48d5e48ef98b

来源与边界

借鉴 TxPert实验重复性基线 的真实子集与未使用细胞比较思想。本次分层100次拆半是项目适配，不是原样复现，也不是 raw-count multinomial采样。共同control参考的噪声也可能影响相关性。

返回图1 | 完整中文结果、协议及产物索引