

Jurkat：三种下采样与原数据的重复性比较

仅采训练扰动细胞；每种固定样本重复100次分层拆半，统一control与5000个基因。

版本	训练细胞	减少比例	Pearson Δ	表达Pearson
原始	128,266	0%	0.3739	0.9732
最多40	47,836	62.7%	0.2618	0.9630
50%	64,475	49.7%	0.2625	0.9518
25%	32,246	74.9%	0.1665	0.9161




图1 | 分布、训练细胞量—重复性、50%对cap40逐条件对照、原细胞数分层。全部图数据见第2页链接。

主要观察

50%保留更多细胞，但总体Pearson Δ 与cap40接近；比例采样减少了小条件的细胞，而cap40完整保留原本 ≤ 40 个细胞的条件。大条件中50%更有优势，详见分层表。

解释边界

25%重复性下降更明显。此结果衡量观测数据稳定性，不是模型分数或理论预测上限；单次seed42采样也不能证明哪种方案训练效果更好。未启动模型训练或切换数据默认。

统计定义、完整产物与版本验收

统一采样与Pearson定义

对条件p的n个训练细胞，50%或25%保留
 $m = \min(n, \max(\min(n, 2), \text{floor}(fn + 0.5)))$ 。batch名额按原比例用最大余数法分配，再无放回随机抽样。单细胞保留1；原有至少2个细胞的条件至少保留2。

所有1335个训练条件、12013个control、41235个验证行、54658个测试行、2805个排除行保持；保留6506变量及原表达。统计使用冻结5000表达基因轴。

每个batch及条件整体两组细胞数相差 ≤ 1 ，随机处理奇数余行。减去原条件batch上下文中的同一个完整control池均值 $c[p]$ ，在基因轴计算：

$r[p,k] = \text{corr}(\mu[A,k] - c[p], \mu[B,k] - c[p])$
先平均100次拆半，再对有效条件等权平均。

1331个有效条件。BIRC5、RACGAP1、ECT2、SEC13各仅1细胞，无法拆半，记缺失而非0。这是同一固定样本的100次拆半；未生成100份采样数据。

原条件细胞数分层

原细胞数	原始	40	50%	25%
1-40	0.269	0.269	0.169	0.095
41-80	0.370	0.302	0.255	0.158
81-160	0.403	0.238	0.288	0.185
>160	0.512	0.209	0.397	0.279

共有866/1309/1319个条件分别在cap40/50%/25%中失去至少一个原batch覆盖。按比例分配不能保证稀有batch都得到1行。所有版本原始参考与分组身份已核对一致。

产物与验收

两种新分析均exit0/COMPLETE，CPU-only、4线程，耗时分别89.42/82.55秒。全部输出哈希、行顺序、obs/var、配额及各267000条逐次记录验收通过；所有保留矩阵值精确不变，原始数据/manifest哈希不变。12项本地及服务器检查通过。

- 每个采样run：
- proportion50.h5ad / proportion25.h5ad：衍生H5AD，仍为analysis-only。
 - selection.json：固定采样行ID与条件清单。
 - repeat_scores.csv：条件×版本×100次记录。
 - conditions.json、summary.json：逐条件与汇总。
 - comparison.png/pdf、receipt、COMPLETE、exit：图和身份收据。前三类只留服务器。

- 四版本比较：
- conditions.json：图1全部逐条件数据。
 - sources.json：三个来源和原统计。
 - comparison.png/pdf、COMPLETE。
 - artifact-index.json：全部图/数据与大小/hash。
 - small-transfer及queue plan/publication/exit/acceptance/tests：安全传输及独立验收。

新分析/比较源码：[8638c6557d779ed2290a00b0882964597ca81d3b](#)
cap40历史源码：[5a8a7bb6712bc4facdfef13d8dd629bd0f250880](#)。各配置、H5AD、control/基因/划分hash均在索引所链接的收据中。

借鉴TxPert真实子集重复性基线；分层100次拆半是项目适配，不声称原样复现。共同control参考噪声和单次采样限制仍存在；总表达高相关不能代替扰动效应稳定性。

[返回图1 | 完整中文结果与所有产物链接](#)