

基因扰动数据集的稳定性与效应结构：观察性综述

范围与结论。本报告只分析真实观测数据：五个独立的细胞内基准数据集，以及另列的四细胞系固定基因轴 cross-cell 缓存。没有使用 GraD-Pert 或其他模型的预测，也没有据此选择超参数或检查点。主要发现是：扰动效应的重复性、每条件细胞数和批次内可比性差异很大；大多数数据集含有明显的共同扰动方向；跨细胞系保留了部分方向相似性，但效应幅度并不相同。由此，单一相关系数不足以描述数据难度。

数据与比较口径

五个基准分别是 Replogle K562、Replogle RPE1、Nadig Jurkat、Nadig HepG2 的未见过单基因扰动，以及 Norman 的已见单基因组成的双基因扰动。前四个基准使用各自冻结的 5,000 个表达基因；Norman 使用 5,045 个。另行分析的 cross-cell 缓存包含 K562、RPE1、Jurkat、HepG2，统一为 K562 来源选择的 3,352 基因轴。它不是四个独立基准的拼接，也不是 TxPert 论文四折分别重选高变基因的精确复现。表 1 中的五数据集数字均来自当前 /data/yilangliu/GraD-Pert/data：EDA、景观、Systema 参照审计、效应图谱及分布审计使用的 canonical H5AD 哈希已逐一核对一致。涉及测试条件真值的统计只用于描述数据，不参与模型选择。

效应拆半使用同一条件的两组细胞均值，各减去同一细胞系的 control 均值；表中为全部合格条件的中位数。从至多 500 个、每个至少有 20 个细胞的条件下，用一半效应检索另一半；Norman 用全部 236 个合格条件。两列来自不同审计的固定口径，不是模型分数。跨数据集表达轴、实验方案和条件组成不同，数值不能直接排成模型“难度榜”。TxPert 将实验拆半作为参照，同时明确它不是性能上界。

五数据集 EDA 还按 control/单基因/双基因、划分和批次分别绘制 PCA/UMAP：K562 图 A1-A2、RPE1 图 A3-A4、Jurkat 图 A5-A6、HepG2 图 A7-A8、Norman 图 A9-A10。当前数据版本的冻结测试条件拆半中，完整表达的相关中位数达 0.981-0.998，而 control 扣除后的效应相关中位数仅为 0.387-0.944；这说明完整表达的高相关很大程度上可能来自共同的基础表达。该图是结构探索，不把 UMAP 距离当作扰动预测准确率。EDA 与表 1 的拆半数值不同，是因为前者只取测试条件、按批次拆分并重复五次，后者汇总全部合格条件。详见 EDA 口径；早期景观结果记录属于旧 data-vnext-a942114 数据版本，本文数值使用当前版本复跑收据。

固定轴 cross-cell 缓存总计 632,488 个细胞；表 2 只列四折所用的四个细胞系（共 581,172 个细胞），排除缓存中另外 51,316 个 K562_adamson 细胞，始终与上面的五个独立数据集分栏解释。

效应强弱、共享方向与稳定性

将每个条件的观测均值减去本细胞系 control 均值后，仍需区分共同方向与条件特异方向。按条件平均的共同效应与单个条件效应的平均余弦，在五个独立数据集中依次为 0.395、0.525、0.290、0.332、0.548（顺序同表 1）。尤其 RPE1 和 Norman 的

共同方向较强。这与 Systema 强调的系统性变化风险相符；这里是我们自己的描述性统计，不能把共同方向直接归因为选择偏差或某一生物机制。

在先前冻结测试条件的审计中，对同一个“训练条件平均效应”的常数基线，只把评估参照从 control 改为训练扰动条件的平均中心，Pearson Δ 中位数便从 K562 0.416 $\rightarrow$ -0.075、RPE1 0.665 $\rightarrow$ -0.050、Jurkat 0.335 $\rightarrow$ 0.091、HepG2 0.368 $\rightarrow$ 0.057、Norman 0.619 $\rightarrow$ 0.134。预测本身没有改变；大幅变化来自评估参照。这是评价指标敏感性的诊断，不是 GraD-Pert 的成绩，也不等同于完全照搬 Systema 的处理流程。原审计及定义。

效应稳定性也取决于统计对象。在至多 500 个条件的效应矩阵上计算的有效秩约为 K562 55.1、RPE1 42.4、Jurkat 102.1、HepG2 65.9、Norman 17.7；这是受基因轴、条件抽样和效应噪声影响的描述量，不能解释成独立生物通路的个数。两半各自绝对效应最大的 20 个基因，其集合 Jaccard 中位数分别为 0.379、0.379、0.176、0.176、0.600。Nadig 两系的头部基因选择尤其不稳定。先前按细胞数分层的测试集审计中，K562 的 20-49 细胞组拆半 Pearson Δ 中位数为 0.447， ≥ 100 细胞组为 0.763；HepG2 分别为 0.213 和 0.684。分层是观察性关联，不能把这两个差值解释为增加细胞数的因果收益。

批次匹配、细胞分布与 guide 证据

批次与扰动标签的原始关联指标在四个单基因数据集为 0.049-0.137；扣除随机置换的有限样本基线后，超额关联只有 K562 0.0005、RPE1 0.0019、Jurkat 0.0006、HepG2 0.0035。但跨批次 control 轮廓通常比同批次 control 更不相似，因而“标签关联弱”不等于“批次效应不存在”。Norman 的 canonical 批次元数据只有一档，无法作跨批次比较。

批次、检索和共同响应的总览见图 1。

本次新增的严格匹配审计对每个条件只选一个批次，并要求该批次中扰动与 control 各至少 20 个细胞。满足要求的条件数见表 3；这比条件总体细胞数更加限制可识别的分布差异。

在匹配样本上，审计使用完整表达轴的固定 96 维高斯随机投影、两组各至多 40 个细胞的无偏 energy statistic、99 次批次内标签置换和所选条件内的 BH 校正。这是有界的分布诊断，不是 scPerturb 官方 E-test 的精确复现；每条细胞系的投影不同，energy 值也不能跨细胞系直接比较。Norman 的 120 个分层抽样

条件中，111 个 (92.5%) 在该样本内达到 $q < 0.1$ 。其他单基因数据集的合格条件过少，不报告显著比例作为全数据集结论。Norman 的等细胞数拆半效应相关 (投影空间) 在每半 10、20、40 个细胞时依次为 0.328、0.525、0.687；这是同一抽样池内的描述性饱和曲线，不宜推断为通用的样本量需求。

guide 身份只在 Replogle RPE1、Nadig Jurkat、Nadig HepG2 的当前 canonical H5AD 中可审计。要求同条件每个 guide 至少 10 个细胞后，独立 guide 对的效应相关中位数分别为 0.082、0.054、0.028，对应 169、169、146 对。它们提示 guide 级一致性不能由条件级拆半替代；但 guide 与批次、目标效率可能混杂，不能直接把低相关解释为纯技术噪声。K562 和 Norman 的这份 canonical H5AD 没有可用的 guide ID，故不伪造 guide 结果。细胞不是独立的生物重复；相关统计不能代替重复实验层面的不确定性分析。Replogle 等描述了 Perturb-seq 的 guide 记录，单细胞差异表达研究说明重复层级的重要性。

基因程序、跨细胞系和双基因结构

以 Enrichr GO Biological Process 2023 中预先指定的八个 GO 项作基因集合，计算每条件集合内表达均值的相对 control 变化。这是程序级描述性汇总，没有逐条件富集检验或因果归因。四个单基因数据集的 DNA replication 与 G2/M 程序共同均值变化均为负；K562 与 Jurkat 的 translation/ribosome biogenesis 共同变化也为负。不过集合覆盖度随基因面板变化，例如 Norman 的 DNA replication 仅覆盖 4 个基因、G2/M 仅 7 个，这两项被标记为不可解释，不与其他数据集比较。

固定轴 cross-cell 四系共有扰动并不能保证同样大小的效应。两两观测效应的 Pearson Δ 中位数跨配对约 0.327-0.491，但 RPE1 相对 K562 的共享条件效应范数比中位数为 1.86 (848 个共享条件)，反向比值为 0.54。先前以其余来源细胞系的同名扰动均值作为描述性参照，对留出细胞系观测效应所得 Pearson Δ 中位数为 K562 0.507、RPE1 0.501、Jurkat 0.427、HepG2 0.480。这些统计使用了目标真值来度量相似性，是迁移难度的背景，不是留一训练模型的成绩；总体 control 扣除仍可能受批次差异影响。

共享扰动的跨细胞系效应参照见图 2。

Norman 的 131 个双基因条件均找到相应两个单基因条件。双扰动观测效应与两个单扰动效应之和的 Pearson 中位数为 0.923，但单位系数可加预测的相对 L2 残差中位数仍为 0.447。允许两个单扰动效应各自拟合系数后，系数中位数为 0.843/0.810，残差中位数降为 0.364；两半独立拟合残差的相关中位数为 0.449。所以数据同时含可加结构和可重复的非加性部分，但尚不能给具体基因对贴上协同、抑制或上位性标签。Norman 原研究与 GEARS 给出了进一步研究遗传互作的背景。

对后续分析的含义与边界

后续若分析模型，应在预先冻结的测试协议下并列报告完整表达、control 扣除效应、以训练扰动中心为参照的特异效应、条件检索，以及按细胞数/批次覆盖度分层的置信信息。这里提

出的是评估设计依据，不代表已经运行这些模型分析。四系跨细胞任务必须明确固定轴还是论文式各折重选基因；五个独立基准也不能被 cross-cell 缓存替换。对双基因效应应同时呈现可加部分和残差。

尚未完成、也不能从当前 canonical 输入可靠推出的项目包括：TxPert 从原始计数拟合多项分布再独立重采样的第二种重复性估计；对全部条件有代表性的批次内 E-test；真实生物重复一致性；全数据集 guide 效率与 target knockdown 验证；单细胞个体因果效应；基于扰动筛选校正的 GO 富集。当前四个单基因 canonical 矩阵的 X 为处理后表达，只有 Norman 暴露 counts 层；即使个别上游文件可能含原始计数，也不能把在 log 表达上 bootstrap 当作 TxPert 的采样估计。UMAP 和上述相关、检索、投影检验均为观察性证据，不能推断因果机制。

可复核记录

- 五数据集 EDA 当前复跑：源码 ecdf8f14a11fde63f6f4cdaecda7c9456c3e96ee，服务器清单 /data/yilangliu/GraD-Pert/development/five-eda-current-ecdf8f1/manifest.json，SHA256 1bcd6d2cf02eb564ffa25d167218ef6c65f07ab403a6ebacee02635cdab5f74；方法见 FIVE_DATASET_EDA.md。

- 六数据集景观当前复跑：同一源码，服务器收据 /data/yilangliu/GraD-Pert/development/six-landscape-current-ecdf8f1/receipt.json，SHA256 c8add3b10259cf05a84b87c5e078674ccab24a9b8b5394627b1bd555d1d9402b。旧版结果记录 SIX_DATASET_LANDSCAPE_RESULTS.md 使用 data-vnext-a942114，不是本文主表的数据版本。

- Systema 启发的参照审计：源码 c25fa0a4be1033d304b4e6bd927a686e883d167a，服务器收据 /data/yilangliu/GraD-Pert/development/systema-audit-c25fa0a/receipt.json，见结果记录。

- 条件效应、GO、guide、交互与跨细胞审计：源码 f7d58a27bc877d5904ba5500cff446aea187e03b，服务器收据 /data/yilangliu/GraD-Pert/development/dataset-effect-atlas-f7d58a2/receipt.json，收据 SHA256 cbc52160f1129c11db5221357db1bf36d9cf890b196160c8e6a103b5577b607d。早期 69aedc5 结果的 Norman 单条件解析错误，已由该版本修复，不用于本报告。

- 批次匹配分布审计：源码 ecdf8f14a11fde63f6f4cdaecda7c9456c3e96ee，服务器收据 /data/yilangliu/GraD-Pert/development/dataset-distribution-ecdf8f1/receipt.json，收据 SHA256 c4fcb226055eb997f613902d56af7a420a5ce30b8fef8bea2d2deefb34c310a6。两项新增审计都以 seed=42、低优先级 CPU、每类 2 个数值线程运行；结果目录只含聚合统计和收据，原始矩阵留在服务器。

所有数值都是这批冻结数据与上述具体代码口径的结果。不同来源、细胞数、基因面板及预处理足以改变数值；论文链接用于说明分析动机和方法背景，并不表示复现了对应论文的全部流程。

全部 12 张已生成图、各分析的聚合统计表和图注见 数据附录。PDF 同时内嵌聚合数据 JSON；逐条件明细仍按上述收据留在服务器。

参考文献与方法来源

下列条目链接至原论文或官方资源。正文中的论文名称可直接打开来源；图号可跳转到本文图页。

1. Wenkel 等, TxPert: using multiple knowledge graphs for prediction of transcriptomic perturbation effects, *Nature Biotechnology*, 2026。
2. Viñas Torné 等, Systema: a framework for evaluating genetic perturbation response prediction beyond systematic variation, *Nature Biotechnology*, 2025。
3. Peidli 等, scPerturb: harmonized single-cell perturbation data, *Nature Methods*, 2024。
4. Norman 等, Exploring genetic interaction manifolds constructed from rich single-cell phenotypes, *Science*, 2019。
5. Roohani 等, Predicting transcriptional outcomes of novel multigene perturbations with GEARS, *Nature Biotechnology*, 2023。
6. Squair 等, Confronting false discoveries in single-cell differential expression, *Nature Communications*, 2021。
7. Replogle 等, Mapping information-rich genotype-phenotype landscapes with genome-scale Perturb-seq, *Cell*, 2022。
8. Enrichr 官方资源及基因集库。

表 1 · 正文数据汇总

独立数据集	细胞数	非 control 条件数	每条件细胞数中位数	条件效应拆半 Pearson Δ 中位数	拆半 Top-1 检索
Replogle K562	161,662	1,092	114	0.621	56.8%
Replogle RPE1	230,244	2,393	66	0.604	52.0%
Nadig Jurkat	238,977	2,392	75	0.326	40.6%
Nadig HepG2	130,879	2,393	40	0.273	32.4%
Norman	91,205	236 (105 单、131 双)	294	0.928	89.4%

表 2 · 正文数据汇总

固定轴细胞系	细胞数	非 control 条件数	每条件细胞数中位数	效应拆半 Pearson Δ 中位数	拆半 Top-1 检索
K562	161,662	1,092	114	0.612	51.2%
RPE1	162,625	1,543	66	0.724	61.6%
Jurkat	156,881	1,491	74	0.483	47.0%
HepG2	100,004	1,653	44	0.380	38.4%




图 1 | X- 前缀指固定轴 cross-cell 缓存，与左侧五个独立数据集区分；右上角的 control 差异为 $1000 \times (1 - \text{Pearson})$ 。底部检索与共同反应图分别反映条件可区分性和共享方向，不能被解释为模型精度。

表 3 · 正文数据汇总

数据来源	同批次合格条件／全部条件	审计中的解释
Replogle K562	8／1,092	可作少数条件的批次内对照，无法代表全数据集
Replogle RPE1	20／2,393	同上
Nadig Jurkat	20／2,392	同上
Nadig HepG2	3／2,393	覆盖尤其不足
Norman	236／236	单批次元数据；按细胞数分层抽取 120 个条件
Cross-cell K562／RPE1／Jurkat／HepG2	8／1,092； 18／1,543； 15／1,491； 2／1,653	与独立基准分开统计，覆盖同样受限




图 2 | 左图是两细胞系共享扰动的观测效应相关中位数；右图用其他细胞系可用的同名扰动观测均值作参照。图中没有训练跨细胞模型。

数据附录：全部图与聚合统计

本附录补齐本轮五项观察性分析实际生成的全部 12 张图，以及其聚合数值。图 A1-A10 为五个独立数据集各自的 PCA/UMAP 和条件拆半图；正文图 1-2 为景观图与跨细胞热图。后续表格按数据来源分别列出统计量，不把固定轴缓存当作独立基准。逐条件 JSON 包含数千条记录，仍保存在服务器收据所列目录，未压成不可读的 PDF 表格。

聚合源文件：docs/experiments/data/report-aggregate-current-ecdf8f1.json；SHA256 d1ff95b33688b75d38c3e477b971aa65ebbbc9792171be1080fd7872729a334f。同一 JSON 也内嵌在 PDF 附件中。它由五项完成的服务器运行导出，只移除了逐条件明细和每批次 control 计数；各运行收据哈希写在源文件的 sources 字段。图 A1-A10 是原始分析 PNG 的等内容、印刷分辨率 JPEG 副本。

A. EDA：细胞组成、PCA 与测试集拆半

数据集	批次数	control／单／双细胞	前两 PC 方差比	表达基因
Replogle K562	48	10,691/150,971/0	0.043	5000
Replogle RPE1	56	11,485/218,759/0	0.092	5000
Nadig Jurkat	55	12,013/226,964/0	0.051	5000
Nadig HepG2	56	4,976/125,903/0	0.095	5000
Norman	1	7,353/48,407/35,445	0.083	5045

数据集	条件×重复数	效应 r 中位	效应 r P05／P95	表达 r 中位
Replogle K562	1365	0.662	0.378/0.946	0.995
Replogle RPE1	2950	0.670	0.186/0.926	0.987
Nadig Jurkat	2950	0.390	0.064/0.821	0.986
Nadig HepG2	2955	0.387	0.044/0.893	0.981
Norman	65	0.944	0.454/0.982	0.998

这两表对应图 A1-A10；拆半仅在冻结测试条件计算，重复五次。Norman 用双扰动条件，其他四项用单扰动条件。前两 PC 方差是可视化抽样的描述，不用于模型评价。

B. 景观：批次、响应与检索

数据来源	标签-批次关联	置换基线	超额关联	同批 control r	跨批 control r
Replogle K562	0.0493	0.0488	0.0005	0.9977	0.9963
Replogle RPE1	0.0822	0.0803	0.0019	0.9962	0.9943
Nadig Jurkat	0.0768	0.0762	0.0006	0.9959	0.9932
Nadig HepG2	0.1369	0.1334	0.0035	0.9920	0.9915
Norman	NA	NA	NA	0.9999	NA
固定轴 K562	0.0493	0.0488	0.0005	0.9980	0.9965
固定轴 RPE1	0.0795	0.0775	0.0020	0.9975	0.9959
固定轴 jurkat	0.0776	0.0767	0.0009	0.9969	0.9945
固定轴 hepg2	0.1312	0.1279	0.0033	0.9949	0.9945

数据来源	RMS 中位	RMS P90	共同响应 r	检索条件	Top-1	Top-10
Replogle K562	0.046	0.078	0.410	500	0.568	0.858
Replogle RPE1	0.068	0.127	0.646	500	0.520	0.722
Nadig Jurkat	0.044	0.089	0.316	500	0.406	0.652
Nadig HepG2	0.049	0.104	0.348	500	0.324	0.558
Norman	0.069	0.114	0.631	236	0.894	0.983
固定轴 K562	0.048	0.084	0.428	500	0.512	0.842
固定轴 RPE1	0.079	0.132	0.734	500	0.616	0.820
固定轴 jurkat	0.054	0.097	0.428	500	0.470	0.750
固定轴 hepg2	0.048	0.102	0.431	500	0.384	0.626

Norman 只有一个 canonical 批次，其跨批统计为 NA。批次关联需与置换基线一起读；检索使用观测拆半效应，不是模型推理。

C. Systema 启发的参照敏感性

数据集	训练条件	测试条件	共同余弦	常数基线 control r	常数基线扰动中心 r	拆半 control r	拆半扰动中心 r
Replogle K562	612	273	0.395	0.416	-0.075	0.625	0.594
Replogle RPE1	1335	590	0.525	0.665	-0.050	0.604	0.627
Nadig Jurkat	1335	592	0.290	0.335	0.091	0.316	0.346
Nadig HepG2	1334	591	0.332	0.368	0.057	0.302	0.358
Norman	206	13	0.548	0.619	0.134	0.942	0.919

数据集	常数基线 centroid 均值/P10/P90	0-19 n/r	20-49 n/r	50-99 n/r	≥100 n/r
Replogle K562	0.500/0.100/0.900	3/0.184	26/0.447	81/0.508	163/0.763
Replogle RPE1	0.500/0.100/0.900	52/0.528	194/0.641	168/0.656	176/0.530
Nadig Jurkat	0.500/0.100/0.900	61/0.046	111/0.220	237/0.359	183/0.455
Nadig HepG2	0.500/0.100/0.900	76/0.152	277/0.213	185/0.476	53/0.684
Norman	0.500/0.100/0.900	0/NA	0/NA	1/0.397	12/0.948

cell-count 分层是测试条件的观察性分组；常数基线的 centroid accuracy 均值约 0.5 是排序恒等性质，不能理解为预测成功率。

D. 条件效应图谱、guide 与 GO 程序

数据来源	条件	<20 细胞	效应 RMS	特异残差 RMS	共同余弦	有效秩	Top20 Jaccard
Replogle K562	1092	8	0.046	0.043	0.395	55.100	0.379

数据来源	条件	<20 细胞	效应 RMS	特异残差 RMS	共同余弦	有效秩	Top20 Jaccard
Replogle RPE1	2393	234	0.068	0.054	0.525	42.380	0.379
Nadig Jurkat	2392	220	0.044	0.042	0.290	102.059	0.176
Nadig HepG2	2393	326	0.049	0.048	0.332	65.930	0.176
Norman	236	0	0.069	0.058	0.548	17.674	0.600
固定轴 K562	1092	8	0.048	0.045	0.410	50.862	0.379
固定轴 RPE1	1543	12	0.079	0.059	0.640	44.190	0.481
固定轴 jurkat	1491	26	0.054	0.050	0.399	75.476	0.290
固定轴 hepg2	1653	40	0.048	0.048	0.401	55.264	0.212

数据集	guide 列	≥2 guide 条件	guide 对	效应相关中位
Replogle RPE1	guide_id	124	169	0.082
Nadig Jurkat	sgID_AB	124	169	0.054
Nadig HepG2	sgID_AB	101	146	0.028

GO 表每格依次为 *覆盖基因数／每条件绝对变化中位数／共同变化*；变化来自观测均值，NA 表示覆盖太低或统计未定义，不是 GO 富集显著性。

数据来源	DNA 复制	DNA 修复	G1/S	G2/M
Replogle K562	30/0.013/-0.016	119/0.006/-0.003	27/0.007/-0.004	18/0.010/-0.007
Replogle RPE1	49/0.049/-0.030	150/0.029/-0.018	35/0.011/-0.009	22/0.046/-0.028
Nadig Jurkat	43/0.012/-0.011	136/0.007/-0.003	34/0.007/-0.002	22/0.012/-0.006
Nadig HepG2	37/0.022/-0.028	115/0.013/-0.015	36/0.006/-0.003	22/0.020/-0.019
Norman	4/NA/NA	18/0.033/-0.031	11/0.029/-0.024	7/NA/NA
固定轴 K562	26/0.013/-0.016	98/0.007/-0.004	19/0.009/-0.006	15/0.012/-0.009
固定轴 RPE1	26/0.070/-0.047	98/0.032/-0.021	19/0.030/-0.022	15/0.052/-0.034
固定轴 jurkat	26/0.022/-0.022	98/0.010/-0.007	19/0.010/-0.004	15/0.017/-0.012
固定轴 hepg2	26/0.029/-0.035	98/0.013/-0.015	19/0.011/-0.011	15/0.027/-0.028

数据来源	细胞凋亡	氧化应激	核糖体生成	翻译
Replogle K562	78/0.006/-0.001	41/0.006/0.005	63/0.024/-0.023	97/0.030/-0.028
Replogle RPE1	83/0.005/-0.000	46/0.007/0.005	81/0.016/-0.010	54/0.014/0.002
Nadig Jurkat	68/0.005/-0.001	34/0.005/0.000	50/0.015/-0.014	49/0.035/-0.015
Nadig HepG2	86/0.005/0.002	44/0.006/0.002	53/0.011/-0.008	37/0.011/-0.003
Norman	65/0.019/-0.014	25/0.019/-0.004	8/NA/NA	11/0.050/-0.055
固定轴 K562	55/0.007/-0.004	32/0.006/0.005	59/0.025/-0.025	95/0.030/-0.028
固定轴 RPE1	55/0.007/-0.002	32/0.016/0.012	59/0.019/-0.000	95/0.030/0.007
固定轴 jurkat	55/0.009/-0.010	32/0.007/-0.001	59/0.025/-0.024	95/0.036/-0.023

数据来源	细胞凋亡	氧化应激	核糖体生成	翻译
固定轴 hepg2	55/0.006/-0.002	32/0.007/0.001	59/0.016/-0.010	95/0.020/-0.010

E. 跨细胞效应与 Norman 双基因结构

目标 <- 来源	共同条件	效应 r 中位	目标/来源范数中位	Top100 符号一致
K562<-RPE1	848	0.403	0.536	0.840
K562<-jurkat	862	0.490	0.772	0.870
K562<-hepg2	875	0.416	0.747	0.850
RPE1<-K562	848	0.403	1.864	0.800
RPE1<-jurkat	1124	0.366	1.354	0.760
RPE1<-hepg2	1229	0.485	1.404	0.870
jurkat<-K562	862	0.490	1.295	0.870
jurkat<-RPE1	1124	0.366	0.738	0.800
jurkat<-hepg2	1191	0.327	0.988	0.780
hepg2<-K562	875	0.416	1.339	0.810
hepg2<-RPE1	1229	0.485	0.712	0.850
hepg2<-jurkat	1191	0.327	1.012	0.750

留出细胞系	源均值可比条件	观测效应与源均值 r 中位
K562	1051	0.507
RPE1	1449	0.501
jurkat	1413	0.427
hepg2	1499	0.480

Norman: 拟合双扰动 131 个; 单扰动系数中位数 0.843/0.810; 单位可加残差 0.447; 拟合残差 0.364; 残差拆半相关 0.449 (131 条件)。

F. 同批次细胞分布检验与样本量曲线

数据来源	合格/全部条件	分析条件	RP96 energy 中位	样本内 q<0.1 比例	log2 方差迹比中位
Replogle K562	8/1092	8	0.597	0.875	0.159
Replogle RPE1	20/2393	20	0.263	0.650	0.076
Nadig Jurkat	20/2392	20	0.067	0.350	0.052
Nadig HepG2	3/2393	3	0.128	0.333	-0.071
Norman	236/236	120	1.167	0.925	0.238
固定轴 K562	8/1092	8	0.390	0.750	0.133
固定轴 RPE1	18/1543	18	0.204	0.444	0.045

数据来源	合格/全部条件	分析条件	RP96 energy 中位	样本内 q<0.1 比例	log2 方差迹比中位
固定轴 jurkat	15/1491	15	0.140	0.333	0.049
固定轴 hepg2	2/1653	2	0.133	0.500	-0.023

数据来源	每半 10: 比较/r	每半 20: 比较/r	每半 40: 比较/r
Replogle K562	24/0.219	NA	NA
Replogle RPE1	60/0.084	21/0.090	3/0.419
Nadig Jurkat	60/0.042	9/0.164	NA
Nadig HepG2	9/0.058	NA	NA
Norman	360/0.328	360/0.525	348/0.687
固定轴 K562	24/0.194	NA	NA
固定轴 RPE1	54/0.123	21/0.188	3/0.496
固定轴 jurkat	45/0.081	6/0.039	NA
固定轴 hepg2	6/0.128	NA	NA

同批次合格条件极少时，q 比例只是被选子集的统计，不能推广全数据集。随机投影每细胞系独立，energy 大小不得跨系比较。

G. 五数据集 PCA/UMAP 与拆半原图

每个数据集单列一页。PCA/UMAP 依次按扰动类别、冻结划分和批次上色；拆半图给出测试条件 Pearson Δ 分布及与条件细胞数的关系。不同嵌入分别拟合，坐标不能跨数据集对齐。

图 A1-A2 | Replogle K562




图 A1 | Replogle K562: PCA/UMAP 按 control/单/双、条件划分、批次上色。




图 A2 | Replogle K562: 测试条件拆半 Pearson Δ 的分布与每条件细胞数。

图 A3-A4 | Replogle RPE1




图 A3 | Replogle RPE1: PCA/UMAP 按 control/单/双、条件划分、批次上色。




图 A4 | Replogle RPE1: 测试条件拆半 Pearson Δ 的分布与每条件细胞数。

图 A5-A6 | Nadig Jurkat




图 A5 | Nadig Jurkat: PCA/UMAP 按 control/单/双、条件划分、批次上色。




图 A6 | Nadig Jurkat: 测试条件拆半 Pearson Δ 的分布与每条件细胞数。

图 A7-A8 | Nadig HepG2




图 A7 | Nadig HepG2: PCA/UMAP 按 control/单/双、条件划分、批次上色。




图 A8 | Nadig HepG2: 测试条件拆半 Pearson Δ 的分布与每条件细胞数。

图 A9-A10 | Norman




图 A9 | Norman: PCA/UMAP 按 control/单/双、条件划分、批次上色。




图 A10 | Norman: 测试条件拆半 Pearson Δ 的分布与每条件细胞数。